RAPPORT — PARTIE I

Analyse des Avis Clients de l'Hôtel De la Promenade

La première partie du projet vise à analyser les **avis clients de l'Hôtel De la Promenade** afin d'identifier :

- Les **forces principales de l'établissement**
- Les **points d'amélioration opérationnels**
- Les **thèmes majeurs présents dans les avis**
- Les **corrélations entre les sujets et le sentiment des clients**

L'objectif est d'extraire des **insights exploitables pour la gestion de l'hôtel**, en utilisant des méthodes de **traitement automatique du langage naturel (NLP)**.

Deux axes analytiques ont été utilisés :

1. **Analyse de sentiment**
2. **Topic Modeling**

Ces approches permettent de comprendre **ce que disent les clients et comment ils le ressentent**.

Made with GAMMA

Préparation et Nettoyage des Données

2.1 Chargement du Dataset

Les données analysées proviennent du fichier :

```
reviews_with_sentiment.csv
```

Ce dataset contient plusieurs colonnes importantes :

- final_text : texte nettoyé de l'avis
- language : langue détectée
- sentiment_label : sentiment final
- normalized_text : version normalisée du texte

Les données sont chargées avec Pandas :

```
df = pd.read_csv("../data/processed/reviews_with_sentiment.csv")
```

Les premières observations confirment que les avis sont **multilingues**, principalement :

- anglais
- français

2.2 Nettoyage des Textes

Avant toute analyse thématique, plusieurs opérations ont été réalisées :

Suppression des valeurs manquantes

Les avis vides sont remplacés par des chaînes vides :

```
df_tm["final_text"] = df_tm["final_text"].fillna("").astype(str)
```

Filtrage des avis trop courts

Les textes contenant moins de trois mots sont supprimés :

```
df_tm = df_tm[df_tm["final_text"].str.split().str.len() >= 3]
```

Cela permet d'éviter que des commentaires très courts (ex : *“good”*, *“ok”*) perturbent l'analyse.

2.3 Stopwords Domaine

Certains mots apparaissent très souvent dans les avis mais n’apportent aucune information utile.

Exemples :

- hotel
- promenade
- ottawa
- room
- chambre

Ces mots sont donc ajoutés dans une liste de **stopwords spécifiques au domaine** :

```
DOMAIN_STOP = { "hotel","promenade","ottawa","room","rooms", "chambre","chambres","stay","stayed",
"la","en","que","qui","sont","etait" }
```

L’objectif est d’éviter que ces mots dominent artificiellement les sujets.

Made with GAMMA

Analyse de Sentiment

3.1 Méthodes Utilisées

Deux modèles de sentiment ont été appliqués :

VADER

Un modèle lexicon-based performant pour les textes courts en anglais.

Transformer (TR)

Un modèle basé sur les **transformers**, plus performant pour capturer le contexte.

3.2 Comparaison des Modèles

Exemple d'observations :

Texte	VADER	Transformer
stayed there because we thought we got a great...	positive	negative
hotel de la promenade was okay	positive	neutral
hotel de la promenade is well-situated but so	negative	neutral
la piscine intérieure est magnifiquement conçue	neutral	positive

Interprétation

Certaines divergences apparaissent :

- **VADER** peut interpréter des mots positifs isolés
- **Transformer** prend davantage en compte le contexte

Exemple :

> "great location but terrible service"

VADER peut détecter "great" et produire un sentiment positif alors que le sentiment global est négatif.

Ainsi, la combinaison des deux méthodes permet une analyse plus robuste.

Made with GAMMA

Topic Modeling avec LDA

4.1 Objectif

Le topic modeling permet d'identifier **les thèmes récurrents dans les avis**.

La méthode utilisée est :

> **Latent Dirichlet Allocation (LDA)**

Cette méthode identifie automatiquement les sujets en fonction de la co-occurrence des mots.

4.2 Vectorisation du Texte

Les textes sont transformés en matrice de fréquence :

```
vectorizer = CountVectorizer( min_df=5, max_df=0.85, stop_words=list(DOMAIN_STOP) )
```

Paramètres utilisés

min_df = 5

Ignore les mots apparaissant moins de 5 fois.

max_df = 0.85

Ignore les mots trop fréquents.

Cela permet d'améliorer la qualité des topics.

4.3 Entraînement du Modèle

Le modèle LDA est entraîné avec :

```
n_topics = 8 lda = LatentDirichletAllocation( n_components=n_topics, random_state=42, learning_method="batch" )
```

Le choix de **8 topics** permet un bon équilibre :

- suffisamment précis
- sans fragmentation excessive

5. Attribution des Topics aux Avis

Chaque avis reçoit :

- un **topic dominant**
- un **score de confiance**

```
doc_topic = lda.transform(X) df_tm["topic_id"] = doc_topic.argmax(axis=1) + 1 df_tm["topic_conf"] =
doc_topic.max(axis=1)
```

Cette étape permet d'analyser :

- la distribution des sujets
- leur relation avec le sentiment

Made with GAMMA

6. Analyse Sentiment par Topic

La distribution des sentiments est calculée :

```
topic_sent = ( df_tm.groupby("topic_id")["sentiment_label"] .value_counts(normalize=True) )
```

Cela permet de déterminer quels sujets sont :

- positifs
- neutres
- problématiques

7. Analyse avec Embeddings

Une seconde méthode de clustering utilise les **embeddings sémantiques**.

Contrairement à LDA :

- LDA utilise la fréquence des mots
- Les embeddings utilisent la **similarité sémantique**

Chaque avis reçoit :

- topic_emb_id
- topic_emb_conf

Cette approche permet de détecter des regroupements plus naturels.

8. Visualisation par Word Clouds

8.1 Word Cloud Global

Un nuage de mots global permet d'identifier les termes les plus fréquents dans l'ensemble des avis.

```
WordCloud( width=1000, height=500, stopwords=custom_stopwords )
```

Cette visualisation donne une vue rapide des thèmes dominants.

8.2 Word Cloud des Avis Négatifs

Un second nuage de mots est généré uniquement à partir des avis négatifs.

Objectif : Identifier les causes principales d'insatisfaction.

8.3 Word Cloud du Topic Critique

Un troisième nuage de mots est généré pour le **Topic 2**, identifié comme le principal cluster problématique.

Cette visualisation permet de comprendre les motifs précis des critiques.

Made with GAMMA

9. Insights Thématiques

Forces Principales

Points Mitigés

Risques Opérationnels

Forces Principales

Topic 3 — Localisation

89.5% positif

La proximité avec :

- Parliament
- ByWard Market
- Rideau Canal

est un facteur majeur de satisfaction.

Topic 8 — Confort et Personnel

85.6% positif

Les clients apprécient :

- la propreté
- le confort
- la qualité du personnel

Le service est un avantage compétitif important.

Topic 1 — Atmosphère et Patrimoine

82.1% positif

Les clients apprécient :

- le caractère historique
- l'atmosphère du lobby

Cela renforce l'identité de l'hôtel.

Points Mitigés

Topic 7 — Spa et Restaurant

61.4% positif

Expérience globalement appréciée mais plus variable.

Topic 4 — Avis Francophones (Décor / Vue)

70.9% positif

Les clients francophones évoquent davantage :

- la vue
- le décor

Topic 5 — Valeur et Taille des Chambres

70.3% positif 13.7% négatif

Certains clients mentionnent :

- chambres jugées petites
- perception prix / valeur.

Risques Opérationnels

Topic 2 — Check-in et Salle de Bain

46% négatif

Principales critiques :

- processus de check-in
- conditions des salles de bain
- interactions avec le personnel de nuit

Il s'agit du **cluster de risque principal**.

Topic 6 — Positionnement Luxe vs Prix

23.6% négatif 32.5% neutre

Certains clients estiment que :

- le prix ne correspond pas toujours au niveau de luxe attendu.

Made with GAMMA

10. Synthèse Stratégique

Forces Clés

- Localisation exceptionnelle
- Personnel apprécié
- Propreté et confort
- Atmosphère historique distinctive

Priorités Opérationnelles

1. Améliorer le processus de check-in
2. Examiner certaines installations de salle de bain
3. Réduire les écarts dans l'expérience spa / restaurant

Considérations Stratégiques

L'hôtel bénéficie d'un positionnement premium mais doit maintenir une cohérence entre :

- prix
- expérience client

11. Conclusion

L'analyse des avis clients permet d'identifier clairement les dynamiques de satisfaction et d'insatisfaction.

Les résultats montrent que :

- la localisation et le service constituent les principaux moteurs de satisfaction
- certaines opérations, notamment le check-in et certaines infrastructures, peuvent générer des critiques

L'approche combinant **analyse de sentiment, topic modeling et visualisation** permet d'obtenir une compréhension complète de l'expérience client.

Ces résultats constituent une base essentielle pour :

- améliorer les opérations
- renforcer la satisfaction client
- orienter les décisions stratégiques de l'hôtel.

Made with GAMMA